


# Kolorwanie obrazów

Jacek Strzałkowski

18.11.2024

# Zdefiniowanie problemu

Problem może być opisany jako klasyfikacja wartości  $a$ ,  $b$  dla danego piksela, gdzie możliwymi klasami będą wartości kolorów.



Dla obrazu zdefiniowanego poprzez wartości oświetlenia  $\mathbf{X}_L \in \mathbb{R}^{H \times W \times 1}$  w jaki sposób przypisać (ang. *halucinate*) obraz zdefiniowany poprzez RGB  $\mathbf{X} \in \mathbb{R}^{H \times W \times 3}$

$$f : \mathbf{X}_L \rightarrow (\mathbf{X}_a, \mathbf{X}_b).$$

Obraz kolorowy  $\mathbf{X}$ : trójka  $(\mathbf{X}_L, \mathbf{X}_a, \mathbf{X}_b)$  , a kanały  $\mathbf{X}_a, \mathbf{X}_b$  chrominance channel (Baldassarre, Morín, and Rodés-Guirao 2017).

# Analiza literatury

Problem kolorowania szarych obrazów jest problemem, dla którego opracowano wiele klasycznych tj. nieMLowych rozwiązań (Žeđer et al. 2021), (Vitoria, Raad, and Ballester 2020).

Przedstawione rozwiązanie wykorzystujące sieć CNN (Zhang, Isola, and Efros 2016) było testowane z wykorzystaniem

- ▶ zbieżność matematyczna klasyfikacji koloru kolorowego oryginału i obrazu uzyskanego z kolorowania. Wynik z kompensacją: 67.3%, bez kompensacji 89.5%.<sup>1</sup>
- ▶ testów *prawdziwości* zdjęć (ang. *perceptual realism*). Użytkownicy byli proszeni o ocenienie, czy zdjęcie było kolorowane sztucznie. Uzyskano wynik **32.3 ± 2.2%**.

---

<sup>1</sup>Kompensacja kolorów jest metodą stosowaną celem ograniczenia zjawiska preferowania przez sieć predykcji popularnych kolorów, skutkującego niewystępowaniem rzadkich kolorów, co powoduje, że takie obrazy wypadają gorzej w testach wykorzystujących ludzi.

- ▶ Wykorzystanie sztucznie kolorowanych obrazów do typowej klasyfikacji klas obiektów ImageNet<sup>2</sup>. Uzyskano 56.0%.

---

<sup>2</sup>Klasyfikacja czy zdjęcie przedstawia obiekt.

Problem może być również wykorzystany przy użyciu sieci **GAN** i *regularyzacji percepcyjnej* - sieć pracuje na poziomie wyższych cech niż pojedyncze piksele (Vitoria, Raad, and Ballester 2020). Do tego celu autorzy wykorzystują przetrenowany model VGG-16.

Poza testami typu *perceptual realism*, przeprowadzono testy numeryczne: PSNR,

$$\text{PSNR} = 10 \cdot \log_{10} \left( \frac{\text{MAX}_I^2}{\text{MSE}} \right),$$

gdzie *MAX* - maksymalna wartość piksela, *MSE* - błąd średnio kwadratowy liczony od wartości pikseli na porównywanych obrazach.

Dla modelu ChromaGAN uzyskano wynik lepszy 25.57 dB niż dla sieci z (Zhang, Isola, and Efros 2016), gdzie było to 22.04 dB.

# Dataset

Sieć będzie trenowana na obrazach w skali szarości, które zostały z konwersji obrazów kolorowych. Uzyskanie datasetu może sprowadzić się więc do zebrania odpowiedniej ilości kolorowych obrazów (czyli użycia datasetu np. do problemu klasyfikacji) i wykorzystania np. programu ImageMagick

```
$ convert color.png -colorspace Gray gray.png
```

Użyty zostanie zbiór danych ImageNet<sup>3</sup>. Zbiór ten zawiera ponad milion obrazków, które mogą posłużyć do treningu,.

---

<sup>3</sup><https://www.kaggle.com/c/imagenet-object-localization-challenge/overview>

# Propozycje rozwiązania

- ▶ Zostanie skonstruowana i wytrenowana sieć CNN zainspirowana (Zhang, Isola, and Efros 2016). Sprawdzone zostaną wymienione funkcje aktywacji i kosztu wymieniane w literaturze odwołującej się do (Zhang, Isola, and Efros 2016).
- ▶ Uwzględnione będą użyte w (Zhang, Isola, and Efros 2016) poprawki na nierównowagę klas (Patrz *kompensacja kolorów*).




Figure 1: Schemat sieci CNN użytej do kolorowania



- ▶ Jeśli to możliwe, przetestowany będzie algorytm GAN opisany w (Vitoria, Raad, and Ballester 2020) wykorzystujący przetrenowane sieci do detekcji cech.
- ▶ Zostanie przygotowany interfejs w przeglądarce, który umożliwi przeprowadzanie testów *perceptual realism*.

## Bibliografia

- Baldassarre, Federico, Diego González Morín, and Lucas Rodés-Guirao. 2017. "Deep Koalarization: Image Colorization Using CNNs and Inception-ResNet-v2." December 9, 2017. <http://arxiv.org/abs/1712.03400>.
- Vitoria, Patricia, Lara Raad, and Coloma Ballester. 2020. "ChromaGAN: Adversarial Picture Colorization with Semantic Class Distribution." January 20, 2020. <https://doi.org/10.48550/arXiv.1907.09837>.
- Žeger, Ivana, Sonja Grgic, Josip Vuković, and Gordan Šišul. 2021. "Grayscale Image Colorization Methods: Overview and Evaluation." *IEEE Access* 9: 113326–46. <https://doi.org/10.1109/ACCESS.2021.3104515>.
- Zhang, Richard, Phillip Isola, and Alexei A. Efros. 2016. "Colorful Image Colorization." October 5, 2016. <http://arxiv.org/abs/1603.08511>.